系统调用追踪

问题:

针对 https://de4dcr0w.github.io/%E5%88%86%E6%9E%90fork%E7%B3%BB%E7%BB%9F%E8%B0%83%E7%94%A8.html, fork 系统调用, linux-4.20 内核,glibc-2.23 版, 通过 GDB 调试跟踪, 给出跟踪过程,并给出自己的心得体会。

搭建 linux-4.20 内核:

- 1. 下载 linux-4.20 源代码: linux kernel 的官方网站为 https://kernel.org/, 由于是海外网站,下载速度比较慢,我去国内镜像源找了找,在阿里云镜像网站 https://developer.aliyun.com/mirror/?serviceType=mirror 的 linux-kernel 镜像找到了 linux-4.20 的备份 https://mirrors.aliyun.com/linux-kernel/v4.x/linux-4.20.tar.gz, 下载速度很快。
- 2. 解压, 我把他解压到了用户家目录, 命令为:

tar -zxf ~/下载/ linux-4.20.tar.gz -C ~

- 3. 编译, 依照 https://mp.weixin.qq.com/s/STExqTiKpGXSp9E DerV6g
 遇到了问题
 - 1. configure: error: Building GCC requires GMP 4.2+, MPFR 2.4.0+ and MPC 0.8.0+. 见 http://www.cnblogs.com/gyfluck/p/10537436.html。
 - 2. [error: '-mindirect-branch' and '-fcf-protection' are not compatible] 原因可能是新版本 gcc 的一些更改出现了 bug,重新安装一遍 gcc-8,可以成功运行。

依照 https://blog.csdn.net/linuxarm123/article/details/99292991 来安装旧版本 gcc,源代码可以去阿里云镜像 http://mirrors.aliyun.com/gnu/gcc 下寻找。

安装文件解压到家目录即可,只需在 make install 时使用 sudo,不必解压到 root 目录在 configure 时建议加入参数—prefix=/usr/local/gcc-8.x 来设置安装目录,不然可能会发生覆盖

安装完成后可以去安装目录下的 bin 目录中使用旧版本 gcc,默认为旧版本参见 https://blog.csdn.net/u012822903/article/details/68934793 的第 6 条,https://blog.csdn.net/mo4776/article/details/119837501 的 "指定 gcc/g++,glibc 的版本进行编译"。

- 3. configure: error: cannot compute suffix of object files: cannot compile 见 https://blog.csdn.net/testcs_dn/article/details/45437149。
- 4. rror: dereferencing pointer to incomplete type 'struct ucontext' 见 https://blog.csdn.net/weixin46584887/article/details/122527357。
- 5. fatal error: sys/ustat.h: No such file or directory
 见 https://blog.csdn.net/weixin 46584887/article/details/122538399。

4. 检查, 依照 https://mp.weixin.qq.com/s/STExqTiKpGXSp9E_DerV6g, 其实文中的 rootfs.img 虚拟硬盘文件可以做得更大一点,以便我们向其中放入更多程序和文件,系统首次加载此虚拟硬盘时是只读的,可以重新挂载: mount -o remount rw/解决。

成功。

安装 glibc-2.23:

- 1. 下载, 阿里云的镜像: https://mirrors.aliyun.com/gnu/glibc/glibc-2.23.tar.gz。
- 2. 安装, 见 https://blog.csdn.net/u010835747/article/details/109624445
- 3. 检查,见 https://www.it1352.com/2686964.html,这里我编译 glibc-ersion.c 时指定了 lib 的目录(glibc-2.23 安装目录下的 lib 目录,我这里已经在 glibc 目录下了,所以是 lib)并设置为了静态连接

gcc -L./lib -O0 -static ~/文档/glibc-version.c -o ~/文档/glibc-version_static

这样内核系统就不用再安装 glibc 了,程序可以直接在内核系统运行,只是程序会比较大。

```
nonkey@monkey-JinGang-T2-S:~/shadisk/share/glibc-2.23$ gcc -L./lib -00 -static ~/文档/glibc-version.
nonkey@monkey-JinGang-T2-S:~/shadisk/share/glibc-2.23$ ~/文档/glibc-version_static
GNU libc version: 2.23
nonkey@monkey-JinGang-T2-S:~/shadisk/share/glibc-2.23$
```

成功。

fork 测试文件

1. 编译测试程序:根据题目提供的网址 https://de4dcr0w.github.io/%E5%88%86%E6%9E %90fork%E7%B3%BB%E7%BB%9F%E8%B0%83%E7%94%A8.html 给出的代码,我进行了拷贝编译,编译参数和 glibc-version 一样

```
gcc -L./lib -O0 -static ~/文档/fork.c -o ~/文档/fork_static
gcc -L./lib -O0 -static ~/文档/fork-asm.c -o ~/文档/fork-asm_static
```

2. 检查运行状况:将编译好的文件放入内核系统的虚拟硬盘(rootfs.img)中,启动内核系统并运行,运行结果如下:

```
/home # ./fork_static
it's a parent process,my process id is 1092
count:1
it's a child process,my process id is 1093
count:1
/home # ./fork-asm_static
it's a parent process,my process id is 1094
count:1
it's a child process,my process id is 1095
count:1
/home # ...
```

成功。

解析 fork()源代码

1. 通过搜索 glibc 目录下的 fork.c, 找到了 fork 的函数定义,实际为__fork__函数:

发现 fork 调用了 ARCH_FORK()位于~/glibc-2.23/sysdeps/unix/sysv/linux/x86_64/archfork.h

```
24 #define ARCH_FORK() \
25 INLINE_SYSCALL (clone, 4,
\
26 CLONE_CHILD_SETTID | CLONE_CHILD_CLEARTID | SIGCHLD, 0,
\
27 NULL, &THREAD_SELF->tid)
```

其又调用了位于同目录下的 sysdep.h 中的 INLINE_SYSCALL 来调用系统调用 clone,还有一堆其他参数:

```
"CLONE_CHILD_SETTID | CLONE_CHILD_CLEARTID | SIGCHLD"
"0"
"NULL"
"&THREAD_SELF->tid"
```



由于 arch-fork 实际上就是一个宏定义,并不是一个函数,所以不能使用 return 语句,因此 arch-fork 的返回值是通过括号内的语句直接返回的。通过一个判断,对其结果 resultval 进行检查,若结果存在问题,则设置错误码,同时将结果置为-1。

"__NR_##name",其中"##"是将##左右两边的标签组合在一起(token pasting or token concatenation)。被展开成为"__NR_clone",此处"__NR_clone"也是一个宏,表示 clone 的系统调用号,通过"INTERNAL_SYSCALL_NCS"函数的第一个参数就把函数名与系统调用号联系了起来。关于系统调用号的定义可在"~/linux-4.20/arch/sh/include/uapi/asm/unistd_64.h"中查找,得到__NR_clone为 120。

详见 https://blog.csdn.net/u012927281/article/details/51540447。

到此为止,系统通过 syscall 进入了系统调用,下面进入内核进行追踪。

使用 GDB 进行跟踪

1. 根据 linux 源代码 kernel/fork.c,发现了系统调用_do_fork,以此为起始断点依次设定了若干可以跟踪 fork 系统调用的断点:

```
(qdb) info b
                       Disp Enb Address
                                                  What
Num
        Туре
                       keep y
                              0xffffffff8105fdd0 in _do_fork at kernel/fork.c:2196
        breakpoint
        breakpoint
                       keep y
                                <MULTIPLE>
                              0xffffffff8105dff0 in copy_process at kernel/fork.c:1677
                               0xffffffff8105fd2b in copy process at ./include/linux/topology.h:80
2.2
2.3
                               0xfffffff8105fe44 in copy_process at kernel/fork.c:1695
                               0xfffffff8105e134 in dup_task_struct at kernel/fork.c:846
        breakpoint
                       keep y
                               0xffffffff81019b00 in copy thread tls
        breakpoint
                       keep y
       breakpoint
                      keep y 0xfffffff81c001d0 arch/x86/entry/entry_64.S:335
```

2. 跟踪 fork.c

跟踪到了到了两个相关的系统调用栈

```
#0 copy_thread_tls (clone_flags=18874385, sp=0, arg=0, p=0xffff888006bd3e80, tls=0)
        at ./arch/x86/include/asm/current.h:15
       0xffffffff8105eccd in copy_process (clone_flags=18874385,
        stack_start=<optimized out>, stack_size=<optimized out>,
        child tidptr=<optimized out>, pid=<optimized out>, trace=<optimized out>,
        tls=<optimized out>, node=<optimized out>) at kernel/fork.c:1931
    #2 0xffffffff8105fead in copy_process (pid=<optimized out>, node=<optimized out>,
        tls=<optimized out>, trace=<optimized out>, child_tidptr=<optimized out>,
        stack_size=<optimized out>, stack_start=<optimized out>,
        clone_flags=<optimized out>) at kernel/fork.c:1713
       _do_fork (clone_flags=18874385, stack_start=<optimized out>,
        stack size=<optimized out>, parent tidptr=0x0 <irg stack union>,
        child_tidptr=<optimized out>, tls=<optimized out>) at kernel/fork.c:2221
    #4 0xffffffff810024f3 in do_syscall_64 (nr=<optimized out>,
        regs=0x0 <irq_stack_union>) at arch/x86/entry/common.c:290
   #5 0xffffffff81c0007c in entry_SYSCALL_64 () at arch/x86/entry/entry_64.S:175
   #6 0x000000000000000 in ?? ()
I.
    #0 copy_thread_tls (clone_flags=18874385, sp=0, arg=0, p=0xffff888006bd4b00, tls=0)
    #1 0xffffffff8105eccd in copy process (clone flags=18874385,
        stack_start=<optimized out>, stack_size=<optimized out>,
        child_tidptr=<optimized out>, pid=<optimized out>, trace=<optimized out>,
        tls=<optimized out>, node=<optimized out>) at kernel/fork.c:1931
   #2 0xfffffffff8105fead in copy_process (pid=<optimized out>, node=<optimized out>,
        tls=<optimized out>, trace=<optimized out>, child_tidptr=<optimized out>,
        stack_size=<optimized out>, stack_start=<optimized out>,
        clone_flags=<optimized out>) at kernel/fork.c:1713
    #3 _do_fork (clone_flags=18874385, stack_start=<optimized out>,
        stack size=<optimized out>, parent tidptr=0x0 <irg stack union>,
        child_tidptr=<optimized out>, tls=<optimized out>) at kernel/fork.c:2221
    #4 0xffffffff810024f3 in do_syscall_64 (nr=<optimized out>,
        regs=0x0 <irq_stack_union>) at arch/x86/entry/common.c:290
    #5 0xffffffff81c0007c in entry_SYSCALL_64 () at arch/x86/entry/entry_64.S:175
   #6 0x0000000000000000 in ?? ()
```

通过和执行 ls 跟踪到的 fork 调用栈对比,可知,我们得到的(I.)调用栈是 shell 执行外部命令时调用的,shell 解释器会调用fork 自身的一个拷贝,然后调用 exec 系列函数来执行外部命令,这样外部命令就取代了先前的子shell。

我们只需观察执行命令后得到的第二个系统调用栈即可。

```
Breakpoint 1, _do_fork (clone_flags=18874385, stack_start=0, stack_size=0, parent_tidptr =0x0 <irq_stack_union>, child_tidptr=0x8f5b50, tls=0) at kernel/fork.c:2196

2196 {
```

停在 do fork 处。可以看到 do fork 有很多参数,其意义分别如下:

- o clone_flags: 子进程创建相关标志,通过此参数来对父进程的资源进行选择的复制
- 。 stack start: 子进程用户堆栈的地址
- stack_size: 用户态堆栈的大小,通常为 0
- parent_tidptr 和 child_tidpre: 父进程和子进程的 pid

copy_process 复制父进程信息,获得 pid、调用 wake_up_new_task 将子进程加入调度队列等 待分配 CPU 资源。

copy_process 调用 dup_task_struct 复制父进程的数据结构、以及进行初始化、信息检查等工作;

```
Breakpoint 4, copy_thread_tls (clone_flags=18874385, sp=0, arg=0, p=0xffff888006bd4b00, tls=0) at ./arch/x86/include/asm/current.h:15
```

copy_process 调用 copy_thread_tls 来初始化子进程的内核栈,设置 pid。

```
Breakpoint 5, ret_from_fork () at arch/x86/entry/entry_64.S:335

movq %rax, %rdi
```

最后从 ret_from_fork 开始执行, 直到结束。

3. 跟踪 fork-asm.c

```
copy thread tls (clone flags=17, sp=0, arg=0, p=0xffff888006bd4b00, tls=0)
    at ./arch/x86/include/asm/current.h:15
#1 0xffffffff8105eccd in copy_process (clone_flags=17, stack_start=<optimized out>,
    stack_size=<optimized out>, child_tidptr=<optimized out>, pid=<optimized out>,
    trace=<optimized out>, tls=<optimized out>, node=<optimized out>)
    at kernel/fork.c:1931
#2 0xffffffff8105fead in copy_process (pid=<optimized out>, node=<optimized out>,
    tls=<optimized out>, trace=<optimized out>, child_tidptr=<optimized out>,
    stack_size=<optimized out>, stack_start=<optimized out>,
    clone flags=<optimized out>) at kernel/fork.c:1713
#3 _do_fork (clone_flags=17, stack_start=<optimized out>, stack_size=<optimized out>,
    parent_tidptr=0x0 <irq_stack_union>, child_tidptr=<optimized out>,
    tls=<optimized out>) at kernel/fork.c:2221
#4 0xffffffff810025eb in do_syscall_32_irqs_on (regs=<optimized out>)
    at arch/x86/entry/common.c:326
#5 do_int80_syscall_32 (regs=0x11 <irq_stack_union+17>) at arch/x86/entry/common.c:349
#6 0xffffffff81c01500 in entry_INT80_compat () at arch/x86/entry/entry_64_compat.S:411
#7 0x000000000000000 in ?? ()
查看 fork 中断的编号:
Breakpoint 6, do_int80_syscall_32 (regs=0xffffc900000eff58) at ./arch/x86/include/asm/ir
qflags.h:52
52
(gdb) info registers
гах
              0x2
调用的参数:
Breakpoint 7, do syscall 32 irgs on (regs=<optimized out>) at arch/x86/entry/common.c:30
              struct thread_info *ti = current_thread_info();
Breakpoint 1, _do_fork (clone_flags=17, stack_start=0, stack_size=0, parent_tidptr=0x0 <
irq_stack_union>, child_tidptr=0x0 <irq_stack_union>, tls=0) at kernel/fork.c:2196
2196
Breakpoint 2, copy_process (pid=<optimized out>, node=<optimized out>, tls=<optimized ou
t>, trace=<optimized out>, child_tidptr=<optimized out>, stack_size=<optimized out>, sta
ck_start=<optimized out>, clone_flags=<optimized out>) at kernel/fork.c:1695
               if ((clone_flags & (CLONE_NEWNS|CLONE_FS)) == (CLONE_NEWNS|CLONE_FS)
Breakpoint 2, copy_process (clone_flags=17, stack_start=0, stack_size=0, child_tidptr=0x
0 <irq_stack_union>, pid=0x0 <irq_stack_union>, trace=0, tls=0, node=-1) at kernel/fork.
1677 __static __latent_entropy struct task_struct *copy_process
Breakpoint 3, dup_task_struct (node=-1, orig=<optimized out>) at kernel/fork.c:846
               (node == NUMA_NO_NODE)
Breakpoint 4, copy thread tls (clone flags=17, sp=0, arg=0, p=0xffff888006bd4b00, tls=0)
at ./arch/x86/include/asm/current.h:15
               return this_cpu_read_stable(current_task);
```

Breakpoint 5, ret_from_fork () at arch/x86/entry/entry_64.S:335

335

系统作了优化,使用 int 80h 系统依旧通过 syscall 来进行系统调用的处理。

感悟

通过查阅源代码我体会到了 c 语言的高深莫测;系统调用的所跟踪出的内核函数复杂而且规模庞大,要读懂他们之间的联系必须很有耐心,逻辑清晰。